

Segmentação e Classificação de Clientes Ford

Retenção na Rede Oficial de Serviços — Relatório de Resultados

Grupo

#	Nome	RM
1	Lucca Borges	554608
2	Ruan Melo	557599
3	Rodrigo Jimenez	558148
4	João Victor Franco	556790

Disciplina: Machine Learning — FIAP × Ford Brasil

Este relatório consolida os achados da solução analítica em duas etapas: (1) segmentação comportamental dos clientes Ford com base no histórico completo (K-means); (2) classificação preditiva multiclasse usando apenas dados do momento da compra. Os 4 perfis levantados pelo gestor (fiel, abandono, esquecido, econômico) são confirmados pelos dados, e o modelo de classificação atinge 72,7% de acurácia e F1 macro 0,70 — sem qualquer vazamento de variáveis pós-compra. Inclui simulação financeira de ROI por estratégia e plano de KPIs de monitoramento operacional.

Sumário Executivo

Objetivo: Aumentar a retenção de clientes Ford na rede oficial.

Dataset: 500.000 clientes Ford com 37 variáveis, separados em Base 1 (histórico, para segmentação) e Base 2 (momento da compra, para classificação).

Etapa 1 — Segmentação: K-means com k=4. ARI 0.5959 — concordância forte com perfil real. Clusters: fiel (30.7%), esquecido (25.7%), econômico (22.6%), abandono (21.1%).

Etapa 2 — Classificação: XGBoost multiclasse com 23 features de Base 2, **sem qualquer variável pós-compra**. Acurácia 72,66%, F1 macro 0,7012.

Achado financeiro: apenas o segmento **esquecido** tem ROI positivo (+184% em 5 anos) considerando receita de revisão isolada. Os demais segmentos precisam considerar LTV expandido.

Métricas-chave

Métrica	Valor	Interpretação
ARI (segmentação)	0.5959	Concordância forte com perfil real
NMI (segmentação)	0.5798	Idem, informação mútua
Silhouette score K-means	~0.45	Clusters bem separados
Accuracy XGBoost	72.66%	Acerta o perfil de 72,7% dos novos clientes
F1 macro XGBoost	0.7012	Performance consistente entre 4 classes
F1 weighted XGBoost	0.7233	Pondera pela frequência de cada classe
Precisão macro	0.7017	Qualidade das predições positivas
Recall macro	0.7043	Cobertura por classe

1. Entendimento do negócio e preparação dos dados

A Ford busca aumentar a retenção de clientes na rede oficial de manutenção. O dataset (500k clientes × 37 colunas) foi separado rigorosamente em duas bases:

- **Base 1 (histórico):** 11 variáveis comportamentais pós-compra — uso restrito à segmentação.
- **Base 2 (momento da compra):** 23 variáveis disponíveis no ato da venda — uso restrito à classificação.

Limpeza aplicada: imputação de NaN com mediana/moda; clipping de outliers em renda e valor no p99; encoding categórico aplicado APÓS o split treino/teste.

Distribuições principais da Base 2:




Figura 1 — EDA das 6 variáveis numéricas centrais da Base 2

2. Segmentação de clientes (K-means)

Aplicamos K-means sobre 7 variáveis comportamentais da Base 1. Escolha de k=4 via elbow + silhouette + aderência conceitual à tipologia do gerente.




Figura 2 — Elbow method e silhouette score

Perfis dos 4 clusters (centroids):




Figura 3 — Heatmap dos centroids normalizados por feature

3. Interpretação semântica dos clusters

Atribuímos os 4 nomes (fiel/abandono/esquecido/econômico) via heurística de ranking. Validamos contra o ground truth perfil_latente:

Cluster	Volume (n)	% do total	Churn cluster	Churn perfil real	Aderência
fiel	153.359	30.7%	2.4%	< 1%	94.1% bate fiel real
esquecido	128.256	25.7%	17.5%	~14%	69.3% bate esquecido real
econômico	112.956	22.6%	8.1%	~6%	81.2% bate econômico real
abandono	105.429	21.1%	33.8%	~50%	69.7% bate abandono real

ARI = 0.5959, NMI = 0.5798 — concordância forte. Observação: o churn por cluster fica diluído porque os clusters K-means não são puros (cluster 'abandono' tem ~70% de abandonos reais).




Figura 4 — Validação cross-tab: % de cada cluster vs perfil real

4. Estratégia de retenção por segmento

Para cada segmento, propomos uma ação coerente com o perfil:

Segmento	Estratégia recomendada	Custo/cliente	ROI esperado
fiel	Tratamento PREMIUM (sem ação ofensiva). Programa fidelidade, participação Alto (pts, service), atendimento humanizado.	Alto (pts, service)	Alto (pts, service)
econômico	INCENTIVO PROMOCIONAL. Voucher 15% revisão + óleo combinado. Médio (pré-pago, promoções, frete grátis).	Médio (pré-pago, promoções, frete grátis)	Médio (pré-pago, promoções, frete grátis)
esquecido	COMUNICAÇÃO ANTECIPADA + conveniência. SMS lembrete 30 dias antes, agendamento 1-clique, leva-e-traz, garantia 3 meses.	Baixo (0,15-3 satias)	Baixo (0,15-3 satias)
abandono	ABORDAGEM CONSULTIVA. Contato proativo do gerente, oferta primeira visita (grátis, diagnóstico técnico no carro).	Muito Baixo (grátis, diagnóstico técnico no carro)	Muito Baixo (grátis, diagnóstico técnico no carro)

Simulação financeira do ROI (horizonte de 5 anos)

Premissas: ticket médio R\$ 1.000 por revisão; margem 35%; horizonte 5 anos; ROI = Lucro preservado / Custo da campanha.

Segmento	n VINs	Receita anual (R\$ M)	Custo 5a (R\$ M)	Receita preservada (R\$ M)	ROI
esquecido	128.256	115,4	6,4	51,9	2.83x (+184%)
fiel	153.359	306,7	38,3	23,0	0.21x (-79%)
econômico	112.956	135,5	112,9	20,3	0.06x (-94%)
abandono	105.429	42,2	158,1	8,4	0.02x (-98%)




Figura 5 — ROI por segmento (esquerda) e receita preservada vs custo (direita)

Conclusão financeira:

- **esquecido: único quick-win puro** (ROI 2.83x, +184%). Custo R\$ 6.4M, receita preservada R\$ 51.9M em 5 anos. **Implementar imediatamente.**
- **fiel** (ROI 0.21x): negativo em receita de revisão isolada, mas justifica-se pela retenção de LTV (recompra do próximo Ford + cross-sell, tipicamente R\$ 5-15k a cada ~5 anos).
- **econômico** (ROI 0.06x): cupom caro frente ao uplift. Aplicar SOMENTE em top 20% LTV individual.
- **abandono** (ROI 0.02x): pior ROI. Não fazer campanha de massa — triagem manual em LTV > R\$ 50k.

5–6. Modelagem preditiva (Base 2 sem leak)

O target supervisionado é o **cluster_name** do K-means (Etapa 1). Features: exclusivamente as 23 variáveis da Base 2. **Variáveis banidas (pós-compra)**: primeira revisão, qtde de revisões em 24m, share na rede, gasto, satisfação 24m, churn observado.

Comparação de algoritmos:

Modelo	Accuracy	F1 macro	F1 weighted	Precision macro	Recall macro
Logistic Regression	0.7180	0.6870	0.7106	0.6887	0.6923
Random Forest	0.7194	0.6872	0.7106	0.6910	0.6942
XGBoost (vencedor)	0.7266	0.7012	0.7233	0.7017	0.7043




Figura 6 — Comparação dos 3 modelos

Performance do XGBoost por classe:

Classe	Precision	Recall	F1	Suporte
abandono	0.5291	0.4435	0.4825	21.086
econômico	0.6401	0.7349	0.6842	22.591
esquecido	0.7040	0.7100	0.7070	25.651
fiel	0.9335	0.9289	0.9312	30.672

XGBoost — Matriz de confusão




Figura 7 — Matriz de confusão do XGBoost

7. Leitura executiva

1) Segmentos encontrados: fiel (30.7%), esquecido (25.7%), econômico (22.6%), abandono (21.1%). Alinhados à tipologia do gerente (ARI 0.5959).

2) Maior risco de evasão: abandono (33.8%) → esquecido (17.5%) → econômico (8.1%) → fiel (2.4%).

3) Sensibilidade a ações comerciais: econômico (preço) e esquecido (conveniência) respondem bem; abandono exige consultoria personalizada; fiel não precisa.

4) Performance do modelo: XGBoost com 72.66% accuracy, F1 macro 0.7012 usando apenas Base 2.

5) Aplicação operacional: CRM captura 23 variáveis no fechamento → XGBoost prediz segmento → playbook automatizado. Re-treino trimestral.

KPIs técnicos (saúde do modelo)

KPI técnico	Threshold de alerta	Frequência	Ação
F1 macro do modelo	< 0.65	Mensal	Re-treinar com 6m de Base 1
Accuracy global	< 70%	Mensal	Auditoria de drift
ROC-AUC por classe	< 0.75	Mensal	Investigar viés por modelo/região
Drift KS-statistic	> 0.10	Semanal	Recalibrar + retreino preventivo
% predições "abandono"	> 30% ou < 10%	Semanal	Investigar outlier de mercado

KPIs de negócio (impacto operacional)

KPI de negócio	Meta	Alerta	Ação
Retenção 24m por segmento	Δ +5pp em 12m	Δ < +2pp em 6m	Revisar playbook
ROI da campanha (5a)	> 2.0x	< 1.0x	Suspender campanha
NPS pós-revisão	> 50	< 30	Auditoria de qualidade
Conversão abandono	> 5% recuperação/ano	< 2%	Repensar abordagem
Custo por cliente retido	< R\$ 200	> R\$ 500	Re-segmentar antes de expandir

SLAs operacionais

- **Scoring:** < 200ms por VIN (predição em tempo real)
- **Deploy:** quinzenal com rollback automático se accuracy cair > 3pp
- **Auditoria humana:** 1% dos clientes de alto LTV (>R\$ 100k) revisados por gerente sênior
- **Re-treino completo:** trimestral, sliding window de 24 meses

Conclusão

- Os 4 perfis hipotetizados são confirmados pelos dados (ARI 0.5959).
- O modelo atinge F1 macro 0.70 usando exclusivamente Base 2 — sem leakage.
- A simulação ROI revela quick-win em esquecidos (R\$ 51.9M / 5a) e justifica priorização de campanhas.
- KPIs e SLAs propostos transformam a POC em ferramenta operacional auditável.
- A solução é deployable: 23 variáveis de input → 1 classe de output → roteamento operacional.

*Notebook executável: [analise_completa.ipynb](#) · Dados: [dados/ford_clientes_historico_completo.csv](#) · Figuras: [figuras/](#)
· Sementes aleatórias fixadas em 42 (reprodutibilidade total).*